

Detekcija karcinoma pluća i debelog creva korišćenjem konvolucione neuronske mreže

Vladimir Čornenki SV53/2021
Nemanja Stjepanović SV75/2021



Definicija problema

- Problem koji se rešava je detekcija karcinoma pluća i debelog creva putem analize histopatoloških slika plućnog tkiva i debelog creva.
- Cilj je razviti klasifikator koji može razlikovati normalno plućno tkivo i debelo crevo od kancerogenog koristeći konvolucione neuronske mreže.




Motivacija

- Detekcija karcinoma pluća ima izuzetan značaj za društvo iz više razloga. Prvo, rano otkrivanje karcinoma ključno je za uspešno lečenje i povećanje šansi za preživljavanje pacijenata.
- Automatizacija ovog procesa pomoću dubokih neuronskih mreža omogućava bržu i precizniju dijagnostiku, što može dovesti do smanjenja vremena čekanja na rezultate i bržeg pristupa lečenju.




Skup podataka

- Skup podataka koji se koristi za detekciju karcinoma pluća i debelog creva sadrži 25.000 histopatoloških slika podeljenih u 5 klasa. Slike su u formatu JPEG i dimenzija 768 x 768 piksela. Skup podataka je generisan iz originalnog uzorka od 750 slika plućnog tkiva (250 benignih plućnih tkiva, 250 adenokarcinoma pluća i 250 skvamoznih ćelija karcinoma pluća) i 500 slika debelog creva (250 benignih tkiva debelog creva i 250 adenokarcinoma debelog creva), koje su potom proširene na 25.000 slika koristeći paket Augmentor. Postoje pet klasa u skupu podataka, pri čemu svaka klasa ima 5000 slika.
- Klase su: Benigno tkivo pluća, Adenokarcinom pluća, Skvamozni ćelijski karcinom pluća, Adenokarcinom debelog creva, Benigno tkivo debelog creva.




Slike pluća



Slike debelog creva

Procesiranje podataka

- Proverava se balansiranost podataka, odnosno da li ima dovoljno primera u svakoj klasi kako bi se izbegla pristrasnost ka većinskim klasama. Korišćenjem ImageDataGenerator iz biblioteke TensorFlow, slike se pripremaju za treniranje. Generatori slika omogućavaju učitavanje slika tokom treniranja, čime se izbegava potreba za učitavanjem svih slika u memoriju odjednom.
- Slike se normalizuju podešavanjem vrednosti piksela na opseg $[0, 1]$ (rescale=1./255). Vizualna provera uzoraka za treniranje pomaže u potvrđivanju pravilne pripreme podataka za treniranje modela





Metodologija

- U metodologiji ovog projekta, pristupamo problemu detekcije raka pluća korišćenjem efikasnih konvolutivnih neuronskih mreža (CNN), sa naglaskom na primenu EfficientNetB3 i ResNet50V2 modela.
- Ovaj pristup uključuje sledeće korake:
 1. Pripremu podataka
 2. Definisanje modela
 3. Treniranje modela
 4. Evaluacija modela
 5. Analiza rezultata



Priprema podataka

- Pripremljeni su podaci za treniranje i evaluaciju modela. To uključuje učitavanje slika pluća iz odgovarajućih datasetova, provera balansa između različitih kategorija, i podela podataka na skupove za treniranje, validaciju i testiranje, podešavanje veličine slika i njihovo normalizovanje (standardizacija osvetljenja i kontrasta slika za bolje rezultate prilikom treniranja modela).

Definisanje modela

- Implementirana su dva modela bazirana na tradicionalnom CNN pristupu i korišćena su dva pretrenirana modela EfficientNetB3 i ResNet50V2 sa dodatim prilagođenim slojevima za klasifikaciju.

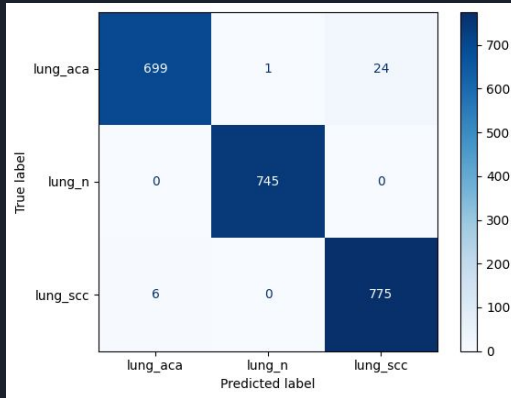


Treniranje modela

- U treniranje modela uključeno je postavljanje optimalnih parametara poput stope učenja, broja epoha i veličine serije, korišćenje Adamax optimizatora za prilagođavanje težina modela, i kontinuirano praćenje tačnosti i gubitka kako bi se izbeglo prenaučenje i osigurao stabilan napredak modela.

Evaluacija

Evaluacija rezultata se vrši kroz korišćenje posebno izdvojenih skupova podataka za treniranje, validaciju i testiranje. Nakon što je model istreniran, koristi se skup za testiranje kako bi se procenila njegova sposobnost generalizacije na novim, neviđenim podacima. Kao metrike evaluacije koriste se tačnost (accuracy), preciznost (precision), odziv (recall), F1-score i matrica konfuzije



Matrica konfuzije

	precision	recall	f1-score	support
lung_aca	0.99	0.97	0.98	724
lung_n	1.00	1.00	1.00	745
lung_scc	0.97	0.99	0.98	781
accuracy			0.99	2250
macro avg	0.99	0.99	0.99	2250
weighted avg	0.99	0.99	0.99	2250

Classification report



Analiza rezultata

- Learning Rate (Stopa Učenja):

Koristili smo različite stope učenja za različite modele. Za EfficientNetB3 i ResNet50V2, početna stopa učenja je bila manja (0.0001) kako bismo izbegli prenaučavanje na unapred treniranim težinama. Tradicionalni CNN je koristio stopu učenja od 0.001.

- Epoche

Svi modeli su trenirani na 20 epoha. Iz rezultata možemo da vidimo da bi određeni modeli bili dovoljno istrenirani i na manjem broju epoha. Zbog toga bi možda najbolje rešenje bilo uvođenje “early stopping-a” kako bi se skratilo vreme potrebno za treniranje.

- Batch Size (Veličina Serije)

Koristili smo batch veličinu od 32 za sve modele.



EfficientNet vs ResNetV2

Arhitektura i dizajn

EfficientNet:

- Koristi princip "compound scaling" za simultano skaliranje širine, dubine i rezolucije mreže.
- Ima modularni pristup gde su slojevi pažljivo dizajnirani kako bi maksimalno iskoristili resurse.
- EfficientNet modeli su numerisani od B0 do B7, gde svaki broj predstavlja različitu veličinu modela.

ResNetV2:

- Koristi rezidualne blokove koji omogućuju direktne prečice (skip connections) između slojeva, čime se rešava problem nestajanja gradijenata u dubokim mrežama.
- ResNetV2 je unapređena verzija ResNeta koja koristi batch normalization pre svake ReLU aktivacije.



EfficientNet vs ResNetV2

Performanse i efikasnost

EfficientNet:

- Dizajniran je da bude izuzetno efikasan u smislu tačnosti po jedinici računske moći.
- U poređenju sa drugim modelima, može postići bolju tačnost uz manji broj parametara i manje operacija (FLOPs).

ResNetV2:

- Fokusira se na povećanje dubine mreže bez gubitka tačnosti, koristeći rezidualne veze.
- Efikasnost može varirati, ali dublje verzije ResNet modela često zahtevaju značajnu računarsku snagu.



EfficientNet vs ResNetV2

Skalabilnost

EfficientNet:

- Skalabilnost je ključna karakteristika. Može se lako prilagoditi različitim potrebama i resursima pomoću "compound scaling" metode.
- Obezbeđuje koherentan način skaliranja koji omogućava bolje performanse na različitim rezolucijama i konfiguracijama.

ResNetV2:

- Može se skalirati povećavanjem broja slojeva (npr. ResNet-50, ResNet-101, ResNet-152), ali ne koristi isti složen pristup skaliranju kao EfficientNet.
- Skalabilnost je više linearna, fokusirajući se na povećanje dubine modela.



EfficientNet vs ResNetV2

Primena

EfficientNet:

- Idealan za primene gde je važna kombinacija visoke tačnosti i efikasnosti, kao što su mobilne i ugrađene aplikacije.
- Često se koristi u zadacima computer visiona gde je bitno balansirati između performansi i resursa.

ResNetV2:

- Koristi se u širokom spektru aplikacija, posebno u scenarijima gde je potrebna velika tačnost i duboka mreža.
- Često se koristi kao osnovni model u mnogim istraživanjima i aplikacijama zbog svoje robusnosti i jednostavnosti.



EfficientNet vs ResNetV2


Tačnost

EfficientNet:

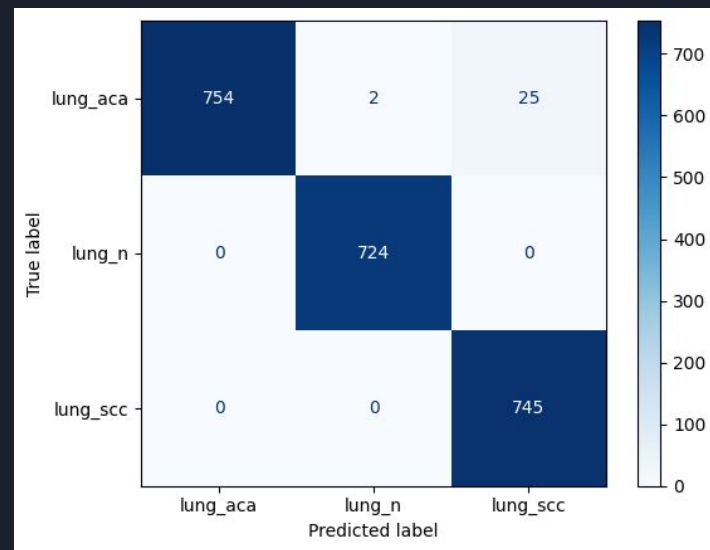
- Dostiže visoku tačnost sa manjim brojem parametara.
- Na mnogim benchmark testovima, EfficientNet je pokazao bolje performanse u poređenju sa mnogim drugim modelima, uključujući ResNet.

ResNetV2:




- Odličan je za duboko učenje i može postići visoku tačnost, ali često zahteva veći broj parametara i više računarskih resursa u poređenju sa EfficientNet-om.



Performanse nakon treniranja CNN za pluća

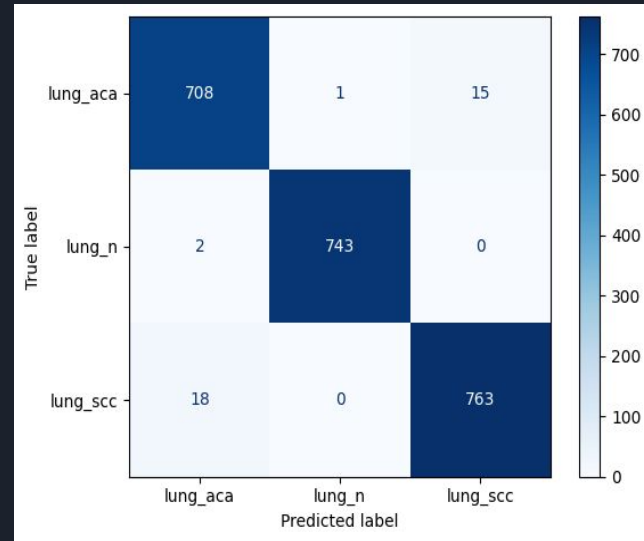
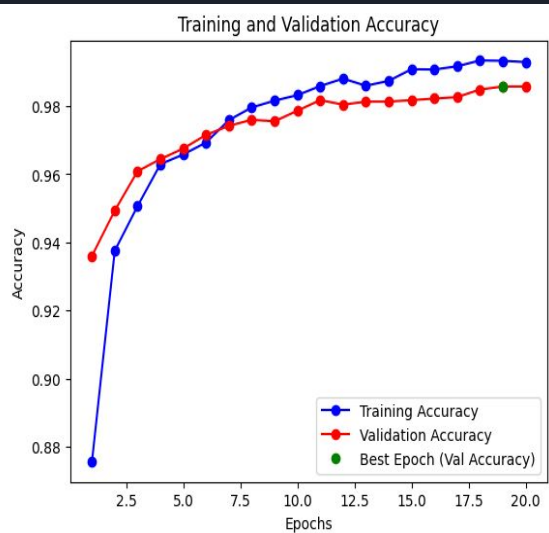



Matrica konfuzije za CNN



Performanse nakon treniranja EfficientNetB3 za pluća

Matrica konfuzije za ENB3



Performanse nakon treniranja ResNet50V2 za pluća

Matrica konfuzije za RN50V2




Analiza performansi

EfficientNetB3:

- Efikasniji je u smislu brzog učenja, ali pokazuje veće fluktuacije koje mogu ukazivati na preprilagođavanje. Može biti potreban pažljiviji pristup regularizaciji kako bi se smanjile fluktuacije.

ResNetV2:

- Pruža stabilnije performanse sa manjim fluktuacijama u gubitku i tačnosti, što može ukazivati na bolju generalizaciju, ali zahteva više epoha da dostigne sličan nivo performansi kao EfficientNetB3.



	precision	recall	f1-score	support
colon_aca	0.97	0.99	0.98	745
colon_n	0.99	0.97	0.98	755
accuracy			0.98	1500
macro avg	0.98	0.98	0.98	1500
weighted avg	0.98	0.98	0.98	1500

Classification report CNN

	precision	recall	f1-score	support
lung_aca	0.99	1.00	1.00	724
lung_n	1.00	1.00	1.00	745
lung_scc	1.00	0.99	1.00	781
accuracy			1.00	2250
macro avg	1.00	1.00	1.00	2250
weighted avg	1.00	1.00	1.00	2250

Classification report ENB3

	precision	recall	f1-score	support
lung_aca	0.97	0.98	0.98	724
lung_n	1.00	1.00	1.00	745
lung_scc	0.98	0.98	0.98	781
accuracy			0.98	2250
macro avg	0.98	0.98	0.98	2250
weighted avg	0.98	0.98	0.98	2250

Classification report RN50V2



Tehnologije

Tehnologije koje su korišćene za izradu ovog projekta:

- Python
- Matplotlib
- Pandas
- Numpy
- Scikit-learn
- TensorFlow



Zaključak

- Projekat je uspešno ostvario ciljeve razvoja klasifikatora za detekciju karcinoma pluća i debelog creva korišćenjem konvolucionih neuronskih mreža.
- Efikasnost modela je procenjena kroz detaljnu evaluaciju, uključujući metrike kao što su tačnost, preciznost, odziv i F1-score. Rezultati su pokazali značajan potencijal za primenu u medicinskoj dijagnostici, posebno u bržoj i preciznijoj detekciji karcinoma.
- Dalja istraživanja mogu poboljšati performanse modela i proširiti njegovu primenu na druge vrste karcinoma. Tehnologija ima potencijal da smanji smrtnost od karcinoma i poboljša pristup lečenju, posebno u područjima sa manjkom medicinskog osoblja.